

Análisis de la Relación entre las Energías Renovables y las Emisiones de CO₂ en Colombia (1990–2021)

Informe Final – Proyecto de Ciencia de Datos

Integrantes

Juan Castillo
Maira Martínez
Jorge Bernal
Samuel Solano

Docente: Camila Silva Gómez

Universidad EAN

Bogotá, Colombia

12 de septiembre de 2026

Índice

1. Planteamiento del Problema y Objetivo del Proyecto	2
2. Búsqueda y Obtención de los Datos	2
3. Comprensión del Conjunto de Datos y Descripción de las Variables	3
4. Proceso de Limpieza y Preparación de los Datos	3
5. Análisis Exploratorio de Datos (EDA)	4
6. Análisis Estadístico	6
7. Hallazgos de Patrones, Relaciones e Insights	7
8. Selección del Modelo y Justificación de su Elección	7
9. Aplicación del Modelo	8
10. Evaluación del Modelo e Interpretación de los Resultados	9
11. Conclusiones y Recomendaciones	10
12. Referencias	11

1 Planteamiento del Problema y Objetivo del Proyecto

Colombia cuenta con una de las matrices eléctricas más limpias de América Latina, con una participación de energías renovables (principalmente hidroeléctrica) que se ha mantenido por encima del 60 % durante todo el periodo 1990–2021. Sin embargo, en ese mismo periodo las emisiones totales de CO₂ del país casi se duplicaron, pasando de 56.9 a 103.7 millones de toneladas. Esta aparente contradicción —una matriz eléctrica mayoritariamente renovable conviviendo con un crecimiento sostenido de las emisiones— motiva la pregunta central de este proyecto.

Pregunta de investigación

¿Qué relación existe entre el crecimiento de las energías renovables y las emisiones de CO₂ en Colombia entre 1990 y 2021?

Objetivo general

Determinar el tipo y la magnitud de la relación entre la participación de energías renovables en la matriz eléctrica y las emisiones de CO₂ per cápita en Colombia, mediante análisis estadístico y modelos de aprendizaje automático aplicados a series de tiempo del periodo 1990–2021.

Objetivos específicos

- Caracterizar la evolución histórica de las emisiones de CO₂, el consumo de energía y la participación renovable en Colombia.
- Cuantificar la correlación entre la participación de renovables, el consumo de energía per cápita y las emisiones de CO₂ per cápita.
- Construir y comparar modelos predictivos que estimen las emisiones de CO₂ per cápita a partir de variables energéticas.
- Identificar cuál de las dos variables predictoras (renovables o consumo energético) tiene mayor peso en la explicación de las emisiones.

2 Búsqueda y Obtención de los Datos

Fuente de los datos

La información utilizada proviene de dos conjuntos de datos públicos publicados por **Our World in Data (OWID)**, alojados en su repositorio oficial de GitHub:

- **CO2 and Greenhouse Gas Emissions Dataset:** <https://github.com/owid/co2-data>
- **Energy Dataset:** <https://github.com/owid/energy-data>

Justificación de la fuente

Se seleccionaron estas fuentes porque: (1) son bases de datos abiertas y de acceso público, sin restricciones de uso académico; (2) se actualizan periódicamente y están respaldadas por instituciones como el Global Carbon Project y la Energy Institute; (3) son ampliamente utilizadas en investigación académica sobre energía y cambio climático, lo que otorga trazabilidad y confiabilidad; y (4) permiten

acceso directo por URL, lo que garantiza la reproducibilidad total del proyecto sin depender de archivos locales.

Método de obtención

Los datos se cargaron directamente en Python mediante `pandas.read_csv()` apuntando a la URL cruda (*raw*) de cada archivo en GitHub, sin necesidad de descarga manual. De ambos conjuntos se extrajeron únicamente los registros correspondientes a **Colombia** en el rango de años **1990–2021**.

3 Comprensión del Conjunto de Datos y Descripción de las Variables

Los datasets originales de OWID contienen decenas de variables para todos los países del mundo. Para este proyecto se filtraron y seleccionaron únicamente las variables relevantes para la pregunta de investigación. Tras el proceso de limpieza, la tabla analítica final (`df_clean`) quedó conformada por:

Variable	Descripción
Year	Año de observación (1990–2021).
CO2_Mt	Emisiones totales de CO ₂ de Colombia, en millones de toneladas (Mt).
CO2_per_capita	Emisiones de CO ₂ por habitante, en toneladas por persona.
Renewables_pct	Porcentaje de electricidad generada a partir de fuentes renovables.
Energy_per_capita	Consumo de energía primaria por habitante.
population	Población total de Colombia para el año correspondiente.

La unidad de análisis es el año-país (Colombia), con 32 observaciones (1990 a 2021), sin valores nulos ni duplicados en el rango seleccionado.

4 Proceso de Limpieza y Preparación de los Datos

El tratamiento de los datos se realizó en Python (`pandas`) siguiendo los pasos que se describen a continuación:

1. **Carga de datos:** lectura directa de los archivos `owid-co2-data.csv` y `owid-energy-data.csv` desde el repositorio oficial de OWID en GitHub.
2. **Filtrado:** de cada dataset se conservaron únicamente los registros donde `country == Colombia` y el año estuviera entre 1990 y 2021.
3. **Selección y renombrado de columnas:** se conservaron las variables relevantes de cada fuente (`co2`, `population` del dataset de emisiones; `renewables_share_elec`, `primary_energy_consumption` del dataset de energía), renombrándolas a nombres más descriptivos.
4. **Unión de tablas:** los dos subconjuntos se combinaron mediante un *merge* por la columna `year`, generando una única tabla (`df_colombia`) con todas las variables alineadas por año.

5. **Cálculo de variables per cápita:** a partir de las variables absolutas y la población, se calcularon `CO2_per_capita` y `Energy_per_capita`, para permitir comparaciones normalizadas por habitante.
6. **Estandarización de nombres:** la columna `year` se renombró a `Year` para mantener consistencia en el resto del análisis.
7. **Consolidación final:** se construyó la tabla analítica `df_clean`, con las seis variables finales listas para el análisis exploratorio, estadístico y de modelado.
8. **Exportación:** la base limpia se exportó a un archivo Excel (`datos_limpios_colombia_1990_2021.xlsx`) para su respaldo y consulta.

Fragmento de código: filtrado, unión y cálculo per cápita

```

1  # Filtrado por país y periodo (1990-2021)
2  col_co2 = df_co2_raw[(df_co2_raw['country'] == 'Colombia') &
3                      (df_co2_raw['year'].between(1990, 2021))].copy()
4
5  # Selección y renombrado de columnas relevantes
6  col_co2 = col_co2[['year', 'co2', 'population']].rename(
7      columns={'co2': 'CO2_Mt'})
8  col_energy = col_energy[['year', 'renewables_share_elec',
9                          'primary_energy_consumption']].rename(
10     columns={'renewables_share_elec': 'Renewables_pct',
11             'primary_energy_consumption': 'Energy_TWh'})
12
13 # Unión de las dos fuentes de datos por año
14 df_colombia = pd.merge(col_co2, col_energy, on='year')
15
16 # Cálculo de variables per cápita
17 df_colombia['CO2_per_capita'] = (df_colombia['CO2_Mt'] * 1e6) / df_colombia['
18     population']
19 df_colombia['Energy_per_capita'] = (df_colombia['Energy_TWh'] * 1e9) / df_colombia[
20     'population']

```

5 Análisis Exploratorio de Datos (EDA)

Evolución de las emisiones de CO₂

Las emisiones totales de CO₂ muestran una tendencia creciente sostenida, con una caída puntual a finales de los años 90 (crisis económica de 1999) y una aceleración marcada a partir de 2005.

Evolución de la participación renovable

La electricidad renovable se mantiene siempre por encima del 60 %, con oscilaciones marcadas en años como 1992 y 2015–2016, coincidentes con periodos de sequía asociados al fenómeno de El Niño, que reduce la generación hidroeléctrica y obliga a un mayor uso de térmicas.




Figura 1: Emisiones de CO₂ en Colombia, 1990–2021.




Figura 2: Participación de electricidad renovable en Colombia, 1990–2021.

Estadística descriptiva

Variable	Media	Mediana	Moda*	Desv. Est.	Asimetría	Mínimo	Máximo
CO ₂ _Mt	70.98	65.33	57.0	15.10	0.72	54.32	103.73
CO ₂ _per_capita	1.68	1.72	2.0	0.21	-0.17	1.31	2.03
Renewables_pct	72.86	72.65	69.0	6.24	-0.07	61.78	83.89
Energy_per_capita	9372.31	9144.85	9041.0	1276.98	0.46	7783.00	11652.96

*Moda calculada sobre valores redondeados.

Las emisiones de CO₂ totales presentan asimetría positiva moderada (0.72), reflejando el crecimiento acelerado de los últimos años del periodo. La participación renovable, en cambio, es la variable más estable (coeficiente de variación de apenas 8.6 %), lo que sugiere que su rol como *driver* directo del crecimiento de emisiones es limitado: no es la variable que más cambia en el tiempo.

6 Análisis Estadístico

Se calculó la matriz de correlación de Pearson entre las cuatro variables numéricas principales:

Matriz de Correlación de Pearson

CO2_Mt	1.000	0.779	-0.235	0.926
CO2_per_capita	0.779	1.000	-0.601	0.690
Renewables_pct	-0.235	-0.601	1.000	-0.131
Energy_per_capita	0.926	0.690	-0.131	1.000
	CO2_Mt	CO2_per_capita	Renewables_pct	Energy_per_capita

Figura 3: Matriz de correlación de Pearson.

Los resultados más relevantes son:

- **Energy_per_capita vs. CO2_Mt:** $r = 0.926$ (correlación positiva muy fuerte).
- **Energy_per_capita vs. CO2_per_capita:** $r = 0.690$ (correlación positiva moderada-alta).
- **Renewables_pct vs. CO2_per_capita:** $r = -0.601$ (correlación negativa moderada).
- **Renewables_pct vs. CO2_Mt:** $r = -0.235$ (correlación negativa débil).




Figura 4: Relación entre renovables (izq.) y energía per cápita (der.) con las emisiones de CO₂ per cápita.

Interpretación

La energía consumida por habitante es, con diferencia, la variable más asociada a las emisiones totales ($r = 0.926$), mientras que la participación renovable tiene una asociación negativa pero moderada con las emisiones per cápita. Esto sugiere que **el volumen de energía consumida pesa más que la composición de la matriz eléctrica** a la hora de explicar el crecimiento de las emisiones en Colombia.

7 Hallazgos de Patrones, Relaciones e Insights

- El crecimiento de las emisiones de CO₂ en Colombia (+82 % entre 1990 y 2021) no está explicado principalmente por cambios en la matriz eléctrica renovable, que se mantuvo relativamente estable y siempre mayoritaria (61.8 %–83.9 %).
- El principal motor de las emisiones es el crecimiento del consumo de energía per cápita, asociado a la expansión económica, el transporte y la industria, sectores donde el país aún depende fuertemente de combustibles fósiles.
- La correlación negativa moderada entre renovables y CO₂ per cápita ($r = -0.601$) indica que, si bien una mayor participación renovable sí se asocia con menores emisiones por habitante, su efecto es parcial: no compensa completamente el crecimiento del consumo energético total.
- Las caídas puntuales en la participación renovable (p. ej. 1992, 2015–2016) coinciden con periodos de menor disponibilidad hídrica, evidenciando la vulnerabilidad estructural de una matriz eléctrica dependiente en gran medida de la hidroelectricidad.

8 Selección del Modelo y Justificación de su Elección

Dado que el conjunto de datos cuenta con un tamaño reducido ($n = 32$ observaciones anuales) y solo dos variables predictoras (**Renewables_pct** y **Energy_per_capita**), se optó por comparar seis modelos de regresión de distinta naturaleza, evaluados todos bajo el mismo esquema de validación:

- **Regresión Lineal, Ridge (L2) y Lasso (L1):** modelos lineales interpretables, útiles como referencia base y para cuantificar la dirección y magnitud del efecto de cada variable.
- **K-Nearest Neighbors (KNN):** modelo no paramétrico capaz de capturar relaciones no lineales entre las variables sin asumir una forma funcional específica.
- **Random Forest y Árbol de Decisión:** modelos basados en árboles, incluidos para explorar posibles relaciones no lineales adicionales, aunque con mayor riesgo de sobreajuste dado el tamaño muestral reducido.

Esquema de validación

Debido al bajo número de observaciones, se utilizó validación cruzada **Leave-One-Out (LOOCV)**, que en cada iteración entrena el modelo con 31 años y predice el año restante, maximizando el uso de los datos disponibles y reduciendo el sesgo de una única partición entrenamiento/prueba.




Figura 5: Comparación de los 6 modelos evaluados mediante LOOCV.

Modelos seleccionados

Con base en el desempeño (R^2 , RMSE y MAE), se seleccionaron dos modelos para el análisis en detalle: **KNN (k=6)**, por ser el de mejor desempeño predictivo, y **Ridge (L2)**, por ofrecer coeficientes interpretables que permiten cuantificar la dirección del efecto de cada variable sobre las emisiones.

9 Aplicación del Modelo

Ambos modelos se implementaron dentro de un *pipeline* de `scikit-learn` que primero estandariza las variables predictoras (`StandardScaler`) y luego ajusta el modelo, evaluando siempre mediante LOOCV:

```

1 X = df_clean[['Renewables_pct', 'Energy_per_capita']]
2 y = df_clean['CO2_per_capita']
3 loocv = LeaveOneOut()
4
5 modelo_ridge = Pipeline([('scaler', StandardScaler()),
6                           ('model', Ridge(alpha=1.0))])
7
8 y_pred_ridge = cross_val_predict(modelo_ridge, X, y, cv=loocv)
9 r2_ridge = r2_score(y, y_pred_ridge)

```

Para KNN se realizó adicionalmente una búsqueda del hiperparámetro k (número de vecinos) probando valores de 1 a 15 y seleccionando el que maximiza el R^2 bajo LOOCV, resultando en $k = 6$ como valor óptimo.




Figura 6: Selección del hiperparámetro k (izq.) y predicción vs. valor real bajo LOOCV (der.) para KNN.

10 Evaluación del Modelo e Interpretación de los Resultados

Modelo	R ²	RMSE	MAE
KNN (k=6)	0.728	0.107	0.076
Ridge (L2)	0.692	0.114	0.093
Regresión Lineal	0.692	0.114	0.093
Lasso (L1)	0.688	0.115	0.094
Random Forest	0.574	0.134	0.090
Árbol de Decisión	0.419	0.156	0.114

El modelo **KNN (k=6)** obtuvo el mejor desempeño predictivo ($R^2=0.728$, el menor RMSE y MAE), superando a los modelos lineales. Los modelos de árboles (Random Forest y Árbol de Decisión) tuvieron el desempeño más bajo, consistente con su tendencia a sobreajustar en muestras pequeñas.




Figura 7: Coeficientes estandarizados del modelo Ridge (izq.) y predicción vs. valor real bajo LOOCV (der.).

Los coeficientes estandarizados del modelo Ridge confirman la dirección de las correlaciones encontradas en el análisis estadístico: el consumo de energía per cápita tiene un efecto **positivo** sobre las

emisiones de CO₂ per cápita, mientras que la participación de renovables tiene un efecto **negativo**, de magnitud ligeramente menor.




Figura 8: Análisis de residuos del modelo KNN (k=6).

El análisis de residuos del modelo KNN no muestra un patrón sistemático evidente (los residuos se distribuyen razonablemente alrededor de cero), aunque existen algunos años con mayor error de predicción, probablemente asociados a condiciones particulares (climáticas o económicas) no capturadas por las dos variables predictoras utilizadas.

11 Conclusiones y Recomendaciones

Conclusiones

- Existe una relación negativa moderada entre la participación de energías renovables y las emisiones de CO₂ per cápita en Colombia ($r = -0.601$), pero esta relación por sí sola no explica el fuerte crecimiento de las emisiones totales observado entre 1990 y 2021.
- El principal factor asociado al crecimiento de las emisiones es el aumento del consumo de energía per cápita ($r = 0.690$ con CO₂ per cápita; $r = 0.926$ con CO₂ total), lo que indica que el problema es más de **volumen de consumo** que de **composición de la matriz eléctrica**.
- El modelo KNN (k=6) permitió predecir las emisiones de CO₂ per cápita con un ajuste razonable ($R^2=0.728$) a partir de únicamente dos variables energéticas, validando la relevancia de ambas variables para el fenómeno estudiado.
- La alta dependencia hidroeléctrica de Colombia genera vulnerabilidad frente a eventos climáticos (El Niño), que reducen momentáneamente la participación renovable y obligan a recurrir a generación térmica.

Recomendaciones

- Diversificar la matriz renovable (solar y eólica) para reducir la dependencia hidroeléctrica y su vulnerabilidad climática.

- Enfocar la política de mitigación no solo en la generación eléctrica, sino en reducir la intensidad energética de sectores como transporte e industria, principales responsables del crecimiento del consumo total.
- Ampliar el análisis incorporando variables adicionales (PIB, emisiones por sector, participación de combustibles fósiles en transporte) que podrían mejorar la capacidad explicativa del modelo.
- Para trabajos futuros, aumentar el tamaño de la muestra (por ejemplo, mediante un panel de varios países de la región) permitiría construir modelos más robustos y generalizables que los obtenidos con $n = 32$ observaciones de un solo país.

12 Referencias

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., & Duchesnay, E. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.

Ritchie, H., Rosado, P., & Roser, M. (2023). *CO₂ and Greenhouse Gas Emissions* [Conjunto de datos]. Our World in Data. <https://github.com/owid/co2-data>

Ritchie, H., Rosado, P., & Roser, M. (2023). *Energy* [Conjunto de datos]. Our World in Data. <https://github.com/owid/energy-data>